## שסדי נתונים ־ תרגיל 4 Join Algorithms - 4

307920116 - רועי בן יוסף 19 בדצמבר 2020

#### שאלה 1

.1

א. עלות החישוב של BNL היא:

$$B(Movies) + B(PlaysIn) \cdot \left\lceil \frac{B(Movies)}{M-2} \right\rceil$$

נחשב את כל אחד מהאלמנטים:

$$B(Movies) = \frac{T(Movies)}{\left|\frac{8192}{36}\right|} = \left[\frac{10000}{227}\right] = 45$$

$$B(PlaysIn) = \frac{T(PlaysIn)}{\left\lfloor \frac{8192}{18} \right\rfloor} = \left\lceil \frac{100000}{445} \right\rceil = 220$$

$$M = 15$$

ולכן עלות החישוב היא:

$$45 + 220 \cdot \left\lceil \frac{45}{13} \right\rceil = 925$$

IO כלומר 925 פעולות

: הוא Hash-Join הוא לקיום אלגוריתם

$$\left\lceil \frac{B(Movies)}{14} \right\rceil \leq 13 \ \lor \ \left\lceil \frac{B(PlaysIn)}{14} \right\rceil \leq 13$$

ומתקיים:

$$\left\lceil \frac{45}{14} \right\rceil = 4 \le 13$$

כלומר ניתן לבצע את האלגוריתם. עלות החישוב של Hash-Join היא:

$$3B(Movies) + 3B(PlaysIn) = 3 \cdot 45 + 3 \cdot 220 = 795$$

: הוא: Sort-Merge-Join הוא:

$$\left\lceil \frac{B(Movies)}{15} \right\rceil < 15 \ \land \ \left\lceil \frac{B(PlaysIn)}{15} \right\rceil < 15$$

ומתקיים:

$$\left\lceil \frac{B(Movies)}{15} \right\rceil = 3 < 15$$

:אך

$$\left\lceil \frac{B(PlaysIn)}{15} \right\rceil = 15 \cancel{1}5$$

. כלומר לא ניתן לממש אלגוריתם Sort-Merge-Join על הטבלאות לממש למותר לא ניתן לממש אלגוריתם

א. כעת M-2=14 לכן עלות החישוב החדשה תהיה:

$$45 + 220 \cdot \left\lceil \frac{45}{14} \right\rceil = 925 = 45 + 220 \cdot \left\lceil \frac{45}{13} \right\rceil$$

כלומר אינה משתנה כלל

ב. נוסחת עלות החישוב של HJ אינה כוללת התייחסות לM. ומכיוון שהאלגוריתם היה בר מימוש

. כאשר M=16 הוא גם יהיה בר מימוש יהיה און און אינוי. M=15

:א: Sort-Merge-Join הוא:

$$\left\lceil \frac{B(Movies)}{16} \right\rceil < 16 \ \land \ \left\lceil \frac{B(PlaysIn)}{16} \right\rceil < 16$$

ואכן מתקיים:

$$\left\lceil \frac{B(Movies)}{16} \right\rceil = 3 < 16$$

$$\left\lceil \frac{B(PlaysIn)}{16} \right\rceil = 14 < 16$$

יעיל: SMJ יעיל אלגוריתם מתקיים התנאי

$$\left\lceil \frac{B(Movies)}{16} \right\rceil + \left\lceil \frac{B(PlaysIn)}{16} \right\rceil < 16$$

$$3 + 14 = 17$$

כלומר לא קיים אלגוריתם יעיל, לכן עלות האלגוריתם תהיה:

$$5B(Movies) + 5B(PlaysIn) = 5 \cdot 45 + 5 \cdot 220 = 1325$$

3

א. בכל מצב, גודל החוצץ הנדרש ל-BNL הוא BNL בלוק אחד ליחס החיצוני, בלוק אחד ליחס הפנימי, ובלוק אחד לפלט.

ב. עבור HJ נדרוש שיתקיים:

$$\left\lceil \frac{B(Movies)}{M-1} \right\rceil \leq M-2 \ \lor \ \left\lceil \frac{B(PlaysIn)}{M-1} \right\rceil \leq M-2$$

הטבלה Movies כוללת פחות בלוקים, ולכן ניתן להתייחס רק אליה, מכיוון שאם בלה הטבלה מקיים, אז גם  $\left\lceil \frac{B(Movies)}{M-1} 
ight
ceil \leq M-2$  מתקיים, אז גם באון אז גם באור בארים באריים מתקיים.

$$\left\lceil \frac{B(Movies)}{M-1} \right\rceil = \left\lceil \frac{45}{M-1} \right\rceil \leq M-2$$

נפתור ונראה כי עבור M=9 מתקיים:

$$\left\lceil \frac{45}{M-1} \right\rceil = 6 \le 7 = M-2$$

:ג. עבור SMJ נדרוש שיתקיים

$$\left\lceil \frac{B(Movies)}{M} \right\rceil < M \ \land \ \left\lceil \frac{B(PlaysIn)}{M} \right\rceil < M$$

הטבלה PlaysIn כוללת יותר בלוקים, לכן ניתן להתייחס רק אליה. כלומר נפתור רק את:

$$\left\lceil \frac{B(PlaysIn)}{M} \right\rceil < M$$

כבר בסעיף הקודם ראינו כי עבור M=15 לא מתקיים התנאי, ועבור M=16 מתקיים. M=16 לכן M=16

יעיל הוא: SMJ יעיל אלגוריתם אלגוריתם ד.

$$\left\lceil \frac{B(Movies)}{M} \right\rceil + \left\lceil \frac{B(PlaysIn)}{M} \right\rceil < M$$

ראינו בסעיף הקודם כי עבור M=16 התנאי אינו מתקיים. עבור M=17

$$\left\lceil \frac{B(Movies)}{17} \right\rceil + \left\lceil \frac{B(PlaysIn)}{17} \right\rceil = 13 + 3 = 16 < 17 = M$$

M=17 כלומר הגודל המינימלי

# שאלה 2

נתון:

$$B(R) = 300, B(S) = 1000$$

$$T(R) = 300 \cdot 100 = 30,000$$

$$T(S) = 1000 \cdot 50 = 50,000$$

$$V(R, B) = 100, V(S, C) = 200$$

$$M = 10$$

א. למדנו שהערכת מספר השורות המתאימות לביטוי זה היא:

$$\frac{T(S)}{V(S,C)} = \frac{50000}{200} = 250$$

ולכן מספר הבלוקים יהיה:

$$\left\lceil \frac{250}{50} \right\rceil = 5$$

כלומר נזדקק ל־5 בלוקים.

ב. במקרה זה אנו לא יודעים את הטווח של A , ולכן הכלל לחישוב מספר השורות המתאימות לרימוני הואי

$$\frac{T(R)}{3} = \frac{30000}{3} = 10000$$

כלומר מספר הבלוקים הוא:

$$\left\lceil \frac{10000}{100} \right\rceil = 100$$

כלומר נזדקק ל־100 בלוקים

ر.

:לכן ב־S, לכן החישוב ניזכר כי B ניזכר ניזכר לצורך

$$V(S,B) = T(S) = 50000$$

:היה:  $\sigma_{A<10 \wedge C=8}(R(A,B)\bowtie S(B,C))$  יהיה: לביטוי המתאימות השורות הספר בסך הכל

$$\frac{T(R) \cdot T(S)}{V(S,C) \cdot \max\{V(R,B),V(S,B)\} \cdot 3} =$$

$$\frac{50000 \cdot 30000}{200 \cdot 50000 \cdot 3} = 50$$

 $a_b$ 

כלומר 50 שורות שונות.

ד. נחשב את עלות החישוב עבור כל אלגוריתם צירוף שלמדנו עליו, נבצע את הבחירה לפני הצירוף בכל אחד מהם ע"מ לצמצם עלויות:

קודם כל נגדיר את היחסים המסוננים:

$$R_A = \sigma_{A < 10} R(A, B)$$

$$S_C = \sigma_{C=8} S(B, C)$$

עלות הביצוע של  $\sigma_{C=8}S(B,C)$  היא או B(S)=1000 או עלות הגישה באמצעות האינדקס. מכיוון שהשימוש באינדקס עצמו זניח, עלות הגישה היא בסך הכל עלות שליפת הבלוק לכל שורה המתאימה לתנאי, כלומר  $T(S_C)=250$ , לכן נשתמש באינדקס. ע"מ ליצור את  $R_A$ נשתמש ב־ $tull\ table\ scan$  מכיוון שאין אינדקס על  $T(S_C)=300$ , אי היא של היחס היא  $T(R_C)=300$ 

כעת נחשב עבור כל אלגוריתם: BNL

$$Read(S_C) + Read(R_A) \cdot \left\lceil \frac{B(S_C)}{M-2} \right\rceil$$

$$250 + 300 \cdot \left\lceil \frac{5}{8} \right\rceil = 550$$

. 550 כלומר העלות היא

 $\cdot INI$ 

עלות החישוב של INL תלויה במספר השורות ביחס הפנימי (עליו יש אינדקס), עלות החישוב תהיה:

$$Read(R_A) + T(R_A) \cdot (cost \ of \ select) =$$

מזניחות הגישה לאינדקס:

$$300 + 10000 \cdot (1) = 10300$$

לכן עלות החישוב תהיה 10300

:HJ

תחילה נבדוק אם מתקיים התנאי לשימוש באלגוריתם:

$$\left\lceil \frac{B(R_A)}{M-1} \right\rceil \leq M-2 \ \lor \ \left\lceil \frac{B(S_C)}{M-1} \right\rceil \leq M-2$$

$$\left\lceil \frac{100}{9} \right\rceil \le 8 \quad \lor \quad \left\lceil \frac{5}{9} \right\rceil \le 8$$

התנאי מתקיים ולכן ניתן להשתמש.

: עלות החישוב של HJ היא

$$Read(R) + Read(S) + 2 \cdot B(R_A) + 2 \cdot B(S_C) =$$

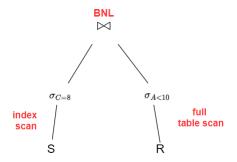
$$300 + 250 + 200 + 10 = 760$$

כלומר עלות החישוב היא 760.

:SMJ

לא נחשב מכיוון שגם במקרה הטוב ביותר, עלות החישוב תהיה זהה לזאת של HJ, ולכן לא אופטימלית.

יותר השאילתה: האילות החתכנית היעילה ביותר היא BNL היעילה היעילה היעילה



ה. כמו שחישבנו בסעיף הקודם, עלות החישוב של תכנית השאילתה היא 550 פעולות IO

### שאלה 3

נתון:

$$B(S) = 1200, \ B(R) = 4000$$

גודל בלוק הוא 2000 בתים גודל שורה ב־S הוא S בתים גודל שורה ב־R הוא S בתים גודל שורה ב־R הוא S בתים בלוק יחיד בS מכיל  $\left\lfloor \frac{2000}{30} \right\rfloor$  שורות, כלומר S שורות. לכן:

$$T(S) = 1200 \cdot 66 = 79200$$

:לכן: שורות. 100שורות, כלומר שורות. לכן: מכיל מכיל מכיל אורות. לכן: בלוק מכיל מכיל מכיל מכיל

$$T(R) = 4000 \cdot 100 = 400000$$

$$V(S, A) = 1000, V(R, A) = 400000$$

$$V(R,B) = 10$$

$$M = 70$$

יהיה:  $\pi_{A,D}\sigma_{B=20\wedge D<5}(R(A,B)\bowtie S(A,C,D))$  יהיה:

$$\frac{T(S) \cdot T(R)}{\max\{V(R,A),V(S,A)\} \cdot V(R,B) \cdot 3} =$$

$$\frac{79200 \cdot 400000}{400000 \cdot 10 \cdot 3} = 2640$$

כלומר יהיו 2640 שורות.

ב. כל שורה מכילה את האטריביוטים A,D . כל אחד מהם שוקל 10 בתים. כלומר גודל

לכן כל בלוק יכיל  $\left\lceil \frac{2640}{100} \right\rceil = 27$  שורות, ולכן נידרש ל $\left\lceil \frac{2640}{100} \right\rceil = 100$  בלוקים. כלומר גודל התוצאה יהיה 27 בלוקים.

ג.נחשב את עלות החישוב עבור כל אלגוריתם צירוף שלמדנו עליו, נבצע את הבחירה לפני הצירוף בכל אחד מהם ע"מ לצמצם עלויות, בנוסף, נבצע הטלות מוקדמות במידת הצורך:

קודם כל נגדיר את היחסים המסוננים לאחר הטלות:

$$R_B = \pi_A \sigma_{B=20} R(A, B)$$

$$S_D = \pi_{A,D} \sigma_{D < 5} S(A, C, D)$$

 $:R_B,S_D$  נחשב את מספר הבלוקים עבור

$$B(R_B) = \frac{400000}{10 \cdot \left[\frac{2000}{10}\right]} = 200$$

$$B(S_D) = \frac{79200}{3 \cdot \left\lceil \frac{2000}{20} \right\rceil} = \frac{79200}{300} = 264$$

כעת נחשב עבור כל אלגוריתם:

:BNL

$$Read(R_B) + Read(S_D) \cdot \left\lceil \frac{B(R_B)}{M-2} \right\rceil$$

$$4000 + 1200 \cdot \left\lceil \frac{200}{70 - 2} \right\rceil = 7600$$

. 7600 כלומר העלות היא

:INL

לא קיים אינדקס ולכן לא נחשב.

:HJ

תחילה נבדוק אם מתקיים התנאי לשימוש באלגוריתם:

$$\left\lceil \frac{B(R_B)}{M-1} \right\rceil \le M-2 \ \lor \ \left\lceil \frac{B(S_D)}{M-1} \right\rceil \le M-2$$

$$\left\lceil \frac{200}{69} \right\rceil \le 68 \quad \lor \quad \left\lceil \frac{264}{69} \right\rceil \le 68$$

התנאי מתקיים ולכן ניתן להשתמש.

 $\colon$ עלות החישוב של HJ היא

$$Read(R) + Read(S) + 2 \cdot B(R_B) + 2 \cdot B(S_D) =$$

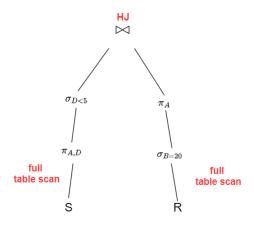
$$4000 + 1200 + 2 \cdot 200 + 2 \cdot 264 = 6128$$

כלומר עלות החישוב היא 6128.

SMJ

, HJ, גם במידה ומתקיים התנאי לחישוב יעיל של אול של איל החישוב שלו תהיה התנאי לכן נעדיף להשתמש ב-HJ.

כלומר האינו שהדרך האופטימלית לחישוב השאילתה היא להלן תכנית השאילתה:



ד. כמו שחישבנו בסעיף ג' , עלות החישוב היא 6128.

### שאלה 4

א. לשאילתה לקח יותר מ־2 דקות לרוץ. תכנון השאילתה להלן:

```
Unique (cost=2461.30..2464.36 rows=175 width=44) (actual time=150.179..150.508 rows=116 loops=1)

-> Sort (cost=2461.30..2461.74 rows=175 width=44) (actual time=150.177..150.299 rows=116 loops=1)

Sort Key: m2.year, m2.duration, m2.movieid, m2.title, m2.rating, m2.genre

Sort Method: quicksort Memory: 36k8

-> Hash Join (cost=1224.25..2454.78 rows=175 width=44) (actual time=74.685..149.989 rows=116 loops=1)

Hash Cond: ((m2.year = m3.year) AND (m2.duration = m3.duration))

-> Seq Scan on movies m2 (cost=0.00..968.00 rows=50000 width=44) (actual time=0.009..36.244 rows=50000 loops=1)

-> Hash (cost=1222.99..1222.99 rows=84 width=8) (actual time=74.667 rows=88 loops=1)

Buckets: 1024 Batches: 1 Memory Usage: 12k8

-> Subquery Scan on m3 (cost=1221.52..1222.99 rows=84 width=8) (actual time=74.258..74.562 rows=90 loops=1)

-> Unique (cost=1221.52..1221.73 rows=84 width=8) (actual time=74.253..74.311 rows=90 loops=1)

Sort Key: (min(m1.duration)), m1.year

Sort Method: quicksort Memory: 29k8

-> HashAggregate (cost=1218.00..1218.84 rows=84 width=8) (actual time=74.110..74.173 rows=90 loops=1)

Group Key: m1.year

-> Seq Scan on movies m1 (cost=0.00..968.00 rows=50000 width=8) (actual time=0.004..33.584 rows=5000 rows=50000 width=8)
```

זמן הריצה כולל תכנון הוא כ150.9 מילישניות. בשאילתה הראשונה ערכנו  $full\,table\,scan$  לכל איבר ב־M1, כלומר למעשה עשינו מכפלה קרטזית, ורק אז סיננון. בשאילתה השנייה, קודם כל סיננו, ורק אז התאמנו את השורות המאימות לאורך הסרט ולשנה. ג. ניתן להשתמש באינדקסים הבאים:

(year) (duration) (year, duration) (duration, year)

מתוכם, נראה שאלה שיועילו יותר יהיו

(year, duration), (duration, year)

מכיוון שהם מספקים גישה מהירה גם לשנה וגם למשך הסרט, המידע הדרוש לנו בעצם. מכיוון שהם מספקים גישה מהירה גם לשנה וגם לעפבי: (year, duration) באופן עקבי:

```
Unique (cost=1949.02..1952.09 rows=175 width=44) (actual time=72.318..72.561 rows=116 loops=1)

-> Sort (cost=1949.02..1949.46 rows=175 width=44) (actual time=72.316..72.390 rows=116 loops=1)

Sort Key: m2.year, m2.duration, m2.movieid, m2.title, m2.rating, m2.genre

Sort Method: quicksort Memory: 36kB

-> Nested Loop (cost=1221.81..1942.50 rows=175 width=44) (actual time=71.386..72.209 rows=116 loops=1)

-> Unique (cost=1221.52..1222.15 rows=84 width=8) (actual time=71.366..71.536 rows=90 loops=1)

-> Sort (cost=1221.52..1222.17 rows=84 width=8) (actual time=71.365..71.420 rows=90 loops=1)

Sort Key: (min(m1.duration)), m1.year

Sort Method: quicksort Memory: 29kB

-> HashAggregate (cost=1218.00..1218.84 rows=84 width=8) (actual time=71.227..71.289 rows=90 loops

Group Key: m1.year

-> Seq Scan on movies m1 (cost=0.00..968.00 rows=50000 width=8) (actual time=0.010..32.185 rows=1 lindex Scan using year dur on movies m2 (cost=0.29..8.55 rows=2 width=44) (actual time=0.003..0.004 rows=1 lindex Cond: ((year = m1.year) AND (duration = (min(m1.duration))))

Planning Time: 0.184 ms

Execution Time: 72.685 ms

(duration quear) Cartyn Ryng (duration = Cartyn Quear) Cartyn Ryng (duration = Cartyn Quear)
```

```
(10 rows)

(10 rows)

(20 rows)

(20 rows)

(3 rows)

(4 ration, year)

(4 ration, year)

(5 rows)

(5 rows)

(5 rows)

(6 rows)

(10 rows)

(11 rows)

(12 rows)

(13 rows)

(14 rows)

(15 rows)

(15 rows)

(16 rows)

(17 rows)

(18 rows)

(18 rows)

(18 rows)

(18 rows)

(18 rows)

(19 rows)

(10 rows)

(11 rows)

(11 rows)

(11 rows)

(11 rows)

(12 rows)

(13 rows)

(14 rows)

(15 rows)

(16 rows)

(17 rows)

(17 rows)

(17 rows)

(18 rows)

(19 rows)

(10 rows)

(
```

נציין גם כי שימוש באינדקסים (year), (duration) האיץ רק במידה מועטת את נציין גם כי שימוש באינדקסים לכל אחד מהם)

נוכל להסביר את ההפרש בזמני הריצה בצורה הבאה:

האינדקס (year, duration) (שחשבנו שיהיה היעיל ביותר) (year, duration) שיצא בשנה נתונה, ומכיוון שהסידור המשני יהיה ע"פ duration, לכל שנה הסרט בעל האורך המינימלי, יהיה הראשון בכל קבוצה של שנה מסוימת. כלומר אם נחפש סרט שיצא בשנה נתונה, הסרט הראשון שניתקל בו, יהיה הסרט בעל האורך המינימלי.

האינדקס (duration, year) מאפשר לנו לגשת בצורה מהירה לסרט בעל האורך המינימלי בשנה נתונה, מכיוון שאנו מסדרים את האינקס קודם כל לפי משך הסרט, נצפה למצוא את כל הסרטים בעלי האורך המינמלי בקיצון הקבוצה. ביצועיו היו טובים באופן מפתיע, חזינו שהוא יתפקד משמעותית פחות טוב מהאינדקס על (year, duration).